

## Aula 5 - Projeto final

Jayme Anchante

1 de março de 2021

construção do modelo: regressão linear

## conceito

*Modelo a relação linear entre uma variável resposta (alvo) e uma ou mais variáveis explicativas (características)*

Fonte

## tipos

Regressão linear simples modela a relação entre uma resposta e uma característica

Regressão linear múltipla modela a relação entre uma resposta e duas ou mais características

# otimização

- ▶ mínimos quadrados ordinários
- ▶ minimização do erro (absoluto ou quadrático)
- ▶ minimização de uma função de custo penalizadora (regressão ridge ou lasso)

## apresentação matemática

Sendo os dados  $\{y_i, x_{i1}, \dots, x_{ip}\}_{i=1}^n$  de  $n$  amostras/linhas e  $p$  variáveis/colunas. A relação linear é modelada por meio de um termo de erro  $\epsilon$ , uma variável aleatória não observável que adiciona/controla o ruído na relação de regressores e regressando tal que

$$y_i = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip} + \epsilon_i = x_i^T \beta + \epsilon_i, \quad i = 1, \dots, n$$

## estimação por mínimos quadrados ordinários

Começando com a proposição inicial que

$$\hat{\beta} = \operatorname{argmin} S(\beta) = \|\mathbf{y} - \mathbf{X}\beta\|^2$$

Depois de algumas transformações, chegamos em

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

## estimação por mínimos quadrados ordinários: regressão simples

$$\hat{\beta} = \frac{\sum x_i y_i - \frac{1}{n} \sum x_i \sum y_i}{\sum x_i^2 - \frac{1}{n} (\sum x_i)^2} = \frac{\text{Cov}[x, y]}{\text{Var}[x]}$$
$$\hat{\alpha} = \bar{y} - \hat{\beta} \bar{x} ,$$



## estimação ingênua

$$\hat{\beta} = ||\mathbf{y} - \mathbf{X}\beta||^2$$

1. Gerar valores (aleatórios) para os  $\beta$
2. Calcular a perda quadrática
3. Se a perda for menor, substituir os melhores parâmetros pelos atuais
4. Voltar ao passo 1

Pode ser incluído um critério de parada opcional baseado em um dos seguintes critérios: i) número de iterações; ii) erro mínimo aceitável; iii) número de iterações sem uma melhora no erro; iv) melhora marginal menor que um mínimo aceitável

## exercício

Sendo os dados de  $X$  e  $y$ :

```
1 import numpy as np
2 rng = np.random.RandomState(42)
3 e = rng.random(100) * rng.randint(1, 50)
4 beta_0 = 3
5 beta_1 = 1.5
6 X = np.linspace(1, 100, 100)
7 y = beta_0 + (beta_1 * X) + e
```

1. Qual são os parâmetros que você deverá encontrar?
2. Plote os dados para explorar suas relações.
3. Escolha um dos métodos de estimação vistos anteriormente e estime os parâmetros?
4. Compare suas respostas com `sklearn.linear_model.LinearRegression` (dica: utilize o método `coef_` do estimador ajustado).

interpretação do modelo: regressão linear

## dados

Base de dados [Guerry do pacote HistData](#) do R. Andre-Michel Guerry (1833) foi o primeiro a sistematicamente coletar dados sociais. As variáveis utilizadas são Lottery (apostas per capita na loteria), Literacy (percentual de militares que são alfabetizados), Wealth (impostos recolhidos per capita), Region (região da França).

```
1 import statsmodels.api as sm
2 df = sm.datasets.get_rdataset("Guerry", "HistData").data
3 columns = ['Lottery', 'Literacy', 'Wealth', 'Region']
4 df = df[columns].dropna()
5 df.head()
```

## regressão linear

```
1 import statsmodels.formula.api as smf
2 formula = 'Lottery ~ Literacy + Wealth + Region'
3 mod = smf.ols(formula=formula, data=df)
4 res = mod.fit()
```

## resultados

```
1 print(res.summary())
```

## informações gerais

```
Dep. Variable:          Lottery
Model:                  OLS
Method:                 Least Squares
Date:                   Fri, 26 Feb 2021
Time:                   00:56:46
No. Observations:      85
Df Residuals:          78
Df Model:               6
Covariance Type:       nonrobust
```

Variável dependente (alvo), data número de linhas/observações, df quer dizer degrees of freedom (grau de liberdade), tipo de covariância (existem diferentes especificações de covariância)

## informações de ajuste

R-squared:	0.338
Adj. R-squared:	0.287
F-statistic:	6.636
Prob (F-statistic):	1.07e-05
Log-Likelihood:	-375.30
AIC:	764.6
BIC:	781.7

- ▶ R2: coeficiente de determinação é a proporção da variância da variável dependente que é explicada pelas variáveis explicativas. [Ver mais.](#)
- ▶ R2 ajustado: o mesmo que o anterior mas ajustado pelo número de colunas. [Ver mais](#)
- ▶ Estatística F: poder preditivo das variáveis explicativas.
- ▶ Probabilidade F: hipótese nula de que o modelo com intercepto e o modelo ajustado são iguais. Um valor menor que 0.05 rejeita esta hipótese com um grau de confiança de 5%.
- ▶ AIC (critério de informação de Akaike) e o BIC (critério de informação de Schwarz) são critérios para seleção de modelo. Quanto menor, melhor.



## coeficientes

	coef	std err	t	P> t	[0.025	0.975]
Intercept	38.6517	9.456	4.087	0.000	19.826	57.478
Region[T.E]	-15.4278	9.727	-1.586	0.117	-34.793	3.938
Region[T.N]	-10.0170	9.260	-1.082	0.283	-28.453	8.419
Region[T.S]	-4.5483	7.279	-0.625	0.534	-19.039	9.943
Region[T.W]	-10.0913	7.196	-1.402	0.165	-24.418	4.235
Literacy	-0.1858	0.210	-0.886	0.378	-0.603	0.232
Wealth	0.4515	0.103	4.390	0.000	0.247	0.656

- ▶ Coeficiente é o valor do beta, o parâmetro que estamos buscando
- ▶ t: teste t cuja hipótese nula é de que o verdadeiro valor do parâmetro é zero
- ▶  $P>|t|$ : caso seja menor que 0.05 rejeitamos a hipótese de que o parâmetro é zero (insignificante)
- ▶ Poderíamos escrever a equação como sendo:

$$y = 38.65 - 15.4Reg[= E] - 10Reg[= N] + \dots - 0.18Lit + 0.45Wel$$

## coeficientes: intercepto

	coef	std err	t	P> t	[0.025	0.975]
Intercept	38.6517	9.456	4.087	0.000	19.826	57.478

- ▶ Intercepto é o valor do alvo caso todas as variáveis independentes sejam zero
- ▶ Interpretação: caso região, alfabetização e riqueza sejam 0, o valor de apostas per capita é 38.65

## coeficientes: região

Region[T.E]	-15.4278	9.727	-1.586	0.117	-34.793	3.938
Region[T.N]	-10.0170	9.260	-1.082	0.283	-28.453	8.419
Region[T.S]	-4.5483	7.279	-0.625	0.534	-19.039	9.943
Region[T.W]	-10.0913	7.196	-1.402	0.165	-24.418	4.235

- ▶ Para fazermos interpretações, precisamos levar em conta sempre a categoria base (oculta)
- ▶ Pessoas da região S jogam, em média, -4.5 francos que pessoas da categoria base (região central), tudo o mais constante (*ceteris paribus*)

## coeficientes: riqueza

Literacy	-0.1858	0.210	-0.886	0.378	-0.603	0.232
Wealth	0.4515	0.103	4.390	0.000	0.247	0.656

- ▶ Para variáveis numéricas, a interpretação é em função da própria unidade da variável
- ▶ A cada um franco a mais de riqueza per capita, a quantidade de francos colocados em aposta per capita é, em média, de 0.45, tudo o mais constante.
- ▶ Vemos que a variável alfabetização não é significativa a 5%, ao contrário da riqueza.

projeto final

## formato

1. 20min de apresentação por pessoa
2. 5min de perguntas da platéia
3. 10min de resposta do apresentador

alunos

a vez de vocês





próximos passos

## assuntos pertinentes

- ▶ nuvem, devops, git, CI/CD, agilidade
- ▶ processamento distribuído, em GPUs
- ▶ aprendizado profundo para reconhecimento de image, vídeo, som e outras aplicações
- ▶ outras linguagens de programação, R, julia, shell
- ▶ praticar, praticar, praticar...